

Tripclick
데이터 파이프라인 프로젝트
(title)

유상준


프로젝트 개요

Tripclick 데이터셋에 대한 정보 설명

가상의 시나리오 구성

=> 여기서 키워드를 뽑고 이걸 주요 목표로 구성하기


시스템 아키텍처 다이어그램



Daily Batch 와 Streaming 두가지가 있는
lambda 아키텍처임을 강조

필요 시 excalidraw 로 다시구성

인프라 구성도



필요 시 excalidraw 로 구성하거나
위치조정 , 제외할수도

메인 이슈 (기술적 challenge)

1. 데이터 중복
2. 에러 처리 , 재실행
3. streaming 최적화

표 형태 구성 , 이슈 해결책 결과 순 구성

데이터셋 설명

,"Url": "http://dx.doi.org/10.1002/14651858.CD008530.pub2", "Title": "Antibiotic therapy for preventing infections
01-01"}]

출처 , 용량 , 칼럼 및 데이터 구성 , 정보 , 타입 등

2013-01-01 ~ 2021-10-30 까지의 데이터를
변형하여 2026 년 1 월 1 일 ~ 1 월 31 일까지 15 시 ~ 16 시 데이터로 생각하고 진행

[TripClick](#)

[Database](#) health web search engine. The clicklog dataset comprises approximately 5.2 million user interactions, collected

저장방식

1. 원본데이터 (Raw data)
2. Kafka 적재되는 데이터
3. 마트 데이터 (배치)
4. 마트 데이터 (실시간) 에 대한 설명

데이터 수집 방법

Json 로그 → kafka 브로커 → Spark 배치 , streamingsql 처리를 통한 pgsql 마트적재 흐름

여기 부분 다이어그램만 확대하여 설명

Producer 역할 , kafka 역할 , consumer 역할에 대한 내용

Why Kafka?

Kafka 를 선택한 이유

(' 내 프로젝트 '에서 왜 kafka 를 사용해야했는지에 대한 이유 중심)

Kafka 구성에 대해 설정값들 설명 (retention, partition 방식 등)

주요 처리로직 Producer

Producer 로직 설명

왜 dockeroperator 로 구성했는지 , 어떤 것들을 고려하여 설정했는지에 대한 내용

Xxhash 기반 값 부여라든지 그런것들 .

주요 처리로직 Consumer(배치)

Spark 배치 적재로직 코드 설명

Sshoperator 사용 이유 및 인프라구성 . 목적 및 처리방식에 대한 설명

주요 처리로직 Consumer(배치)

Spark 배치 적재로직 코드 설명

Sshoperator 사용 이유 및 인프라구성 . 목적 및 처리방식에 대한 설명 , 전략

주요 처리로직 Consumer(실시간)

Spark 실시간 처리로직 코드 설명

Sshoperator 사용 이유 및 인프라 구성 . 목적 및 처리방식에 대한 설명 , 전략

microbatch 를 어떻게 설정했고 하는 내용들

Why Airflow?

Airflow 를 사용한 이유에 대한 설명

장점 및 아키텍처 구성에 대한 설명 . oozie 같은 도구를 써봤으니 이와 비교한 장점 등

BI 마트 구성내용

Apache Superset + pgsql 조합 기반의 구성

왜 이 기술을 선택했는지에 대한 설명

대시보드 구성

Daily 배치 기반 마트 내용 차트 및 대시보드 내용 설명

실시간 스트리밍 처리 내용 차트 및 대시보드 내용 설명

TODO 다음에 더 개선해야할 부분

모니터링 및 알림구성 (Prometheus + Grafana, Loki, email 전송) 같은 내용들

CI/CD 전략내용 . gitlab 같은 배포구성에 대한 설명들